

신체측정 모델 평가

평가 기준은 현재 서빙하는 14개 저장 항목이다. 과거 (키-살높이)/살높이 비율식 결과와 아래 § 6의 legacy 11-target 실험은 현재 평가에 포함하지 않는다.

1. 서빙 조합 — 모델 3개를 합쳐 14개를 만든다

`estimate_from_basic()`은 모델 하나가 아니라 세 개를 순서대로 호출해 합친다. 학습 데이터가 서로 다르기 때문이며, 정확도를 인용할 때 어느 모델의 숫자인지 반드시 밝혀야 한다.

출력	개 수	모델 artifact	학습 모집 단	지표 파일
chest waist hip shoulder	4	hist_gradient_boosting_181.joblib	SizeKorea 8차 직접측 정 181명 프로필 (학 습 172행)	metrics_181.json
thigh calf arm	3	hist_gradient_boosting_circumference.joblib	위와 같은 직접측정 계열 (학습 178행)	metrics_circumference
thigh_length calf_length torso_length leg_length neck_length	5	hist_gradient_boosting_exact_lengths_v2.joblib	SizeKorea 8차 3D 측 정 (원천 4,545행 → 정제 4,485행)	metrics_exact_lengths
thigh_calf_ratio torso_leg_ratio	2	모델 없음 — 서버 후처리 나눗셈	—	위 파일의 cv5_postproce

✅ 근거: `src/inference.py:326~356 (estimate_from_basic) · manifest_181.json`의 `serving_status: "core_measurements_only", serving_targets: [chest, waist, hip, shoulder] · docs/api_mobile_change_notes.md:19`

⚠️ 직접측정 계열과 3D 계열은 같은 사람이 아니다. 3D 원천 4,545명과 이미지 181명은 `subject_id` 교집합이 0명이다 (8개 항목 최근접 L1거리 최소 4.46cm, 0거리 0명). 둘레 정확도와 길이 정확도를 하나의 근거로 묶어 말하면 안 된다.

⚠️ 행 수 172 / 178 / 181은 같은 모집단의 서로 다른 카운트다(프로필 181, 각 타겟의 결측 제외 후 학습 행). 임의로 하나로 통일하지 말고 인용하는 지표 파일이 적은 수를 그대로 쓴다.

2. 서빙 모델 지표 (전부 shuffled 5-fold CV)

2.1 코어 둘레 4개 — metrics_181.json (172행)

항목	MAE (cm)	RMSE	R ²
shoulder	1.541	1.862	0.593
hip	2.306	2.958	0.726
chest	3.043	3.845	0.727

항목	MAE (cm)	RMSE	R ²
waist	3.406	4.657	0.761

`metrics_181.json`에는 12개 타깃이 모두 들어 있지만, 서빙에 쓰는 것은 위 4개뿐이다. 같은 파일의 `thigh/calf/arm` 행(2.379 / 1.294 / 1.247)은 서빙 값이 아니므로 인용하지 않는다 — 서빙 값은 § 2.2다. 같은 파일의 길이 5개 행도 서빙하지 않는다(§ 4 참조).

2.2 부가 둘레 3개 — `metrics_circumference.json` (178행)

항목	MAE (cm)	RMSE	R ²
arm	1.170	1.446	0.775
calf	1.183	1.528	0.619
thigh	2.223	2.826	0.645

⚠ 이 모델만 학습 스크립트가 `scripts/`에 없다. artifact와 지표·행별 예측 (`predictions/circumference_cv_predictions.csv`, 178행, 컬럼 = thigh/calf/arm)은 서로 일치하지만 재현 스크립트가 없어 재학습 경로가 끊겨 있다. 재학습이 필요해지면 스크립트부터 복원해야 한다.

2.3 길이 5개 + 비율 2개 — `metrics_exact_lengths_v2.json` (4,485행)

항목	MAE	RMSE	R ²
neck_length	0.917 cm	1.159	0.256
calf_length	1.065 cm	1.347	0.776
thigh_length	1.396 cm	1.804	0.405
leg_length	1.537 cm	1.988	0.857
torso_length	1.660 cm	2.169	0.439
thigh_calf_ratio	0.046	0.058	0.292
torso_leg_ratio	0.028	0.037	0.020

2.4 해석 — 숫자를 인용할 때의 전제

- 한 범위로 묶지 않는다. 길이는 0.92~1.66cm, 둘레는 1.17~3.41cm다. "MAE 1~1.6cm"처럼 말하면 허리(3.406)에서 2배 이상 틀린 주장이 된다.
- 가장 어려운 부위가 가장 중요한 부위다. 허리 3.406 / 가슴 3.043으로 오차가 가장 큰데, 상·하의 사이즈를 결정하는 것이 바로 이 두 부위다. 사진(VLM) 경로를 둔 이유가 여기 있다.
- `neck_length`는 키·몸무게로 예측되지 않는다(R^2 0.256). 정의를 4가지로 바꿔 재봐도 5-fold R^2 가 -0.36~0.10이라 사실상 집단 평균이다. 실제 값은 사진 경로로만 얻을 수 있다.
- `torso_leg_ratio`는 MAE 0.028로 작지만 R^2 0.020이다. 개인별 미세 차이는 잡지 못하므로 사진 측정값 또는 사용자 수정값을 우선한다.

3. VLM 실행 기준

새 실행부터 VLM은 ratio를 직접 반환하지 않고 `thigh_length_cm`, `calf_length_cm`, `torso_length_cm`, `leg_length_cm`를 반환한다. 정렬 스크립트는 `thigh_length/calf_length`, `torso_length/leg_length`로 ratio를 재계산한다. 기존 실행분처럼 support length가 없으면 기존 ratio 컬럼을 fallback으로 사용하고, 없는 길이 컬럼은 비워 둔다.

서빙 길이 랜드마크 계약(= `manifest_exact_lengths_v2.json`의 `length_definitions`)은 다음과 같다.

필드	정의
<code>thigh_length</code>	살높이 - 무릎뼈가운데높이
<code>calf_length</code>	무릎뼈가운데높이 - 가쪽복사높이
<code>torso_length</code>	어깨높이 - 위앞엉덩뼈가시높이(골반점)
<code>leg_length</code>	위앞엉덩뼈가시높이(골반점) - 가쪽복사높이
<code>neck_length</code>	턱끝높이 - 목앞높이. 사진에서 7~12cm는 soft plausibility guide이며 clipping 또는 실패 조건이 아니다.

⚠ `manifest_181.json`에도 `length_definitions`가 있지만 옛 정의다 (`leg_length` = 살높이, `calf_length` = 무릎높이). 그 모델의 길이 출력은 서빙하지 않으므로 (§ 1) 위 표만 유효하다. 두 매니페스트의 정의가 다른 것은 오류가 아니라 세대 차이다. `comparison_exact_lengths_v2.json`이 그 차이를 정량화해 둔다 — 옛 정의를 3D 정확 정의 정답에 직접 대면 `calf_length` MAE가 2.423cm로, v2(1.065cm)의 2배 이상이다.

3.1 VLM 재학습·재평가를 하지 않는 이유

`data/people`의 앞·옆 사진 181명은 복구된 same-image profile과는 연결되지만, 3D 원천 4,545명과 `subject_id` 교집합이 없다. same-image profile에는 가쪽복사·어깨선·골반점·턱끝·목앞 랜드마크가 없으므로 새 정의의 `calf_length`, `torso_length`, `leg_length`, `neck_length` 정답을 만들 수 없다. `build_vlm_image_ground_truth.py`는 이 값을 proxy로 채우지 않고 `NULL`로 보존한다.

따라서 VLM 자체 재학습은 하지 않는다. 프롬프트 변경 후에는 성별과 키·몸무게 구간을 총화한 소규모 표본으로 새 응답의 안정성을 먼저 확인하고, 정확도 평가는 새 랜드마크를 가진 동일 인물 사진을 확보한 뒤 수행한다. 현재 181 명으로는 둘레·어깨와 `thigh_length`만 정량 평가할 수 있고, 나머지 길이는 응답률·물리적 일관성·반복 호출 변동만 검증할 수 있다.

새 `leg_length`가 기존 살점 기준 결과보다 커지는 것은 정의 변경에 따른 정상 변화다. 비율이 참과 분포 밖이어도 실패 처리하지 않는다. 필수 키 누락, 숫자 변환 실패, 0 이하 분모만 실패로 본다.

⚠ 이전 판에는 총화 표본 생성 명령 (`python ml/body_measurement/scripts/select_vlm_landmark_v2_sample.py --per-gender 6`)이 적혀 있었으나 해당 스크립트는 저장소에 없다. 총화 표본이 필요하면 스크립트를 먼저 작성한다.

4. 사진 vs 무사진 A/B

사진 경로를 왜 두는지에 대한 정량 근거는 이 문서가 아니라 `docs/body-measurement-api-design.md` § 7.2에 있다 (143명, 부위별 MAE). 결론만 옮기면, 사진은 가슴·허리에서만 확실히 낮고 나머지 5개 부위는 무사진이 낫다. 집계 기준을 3개(가슴·허리·엉덩이)로 잡으면 사진이, 7개 전체로 잡으면 무사진이 이긴다. 성능을 인용할 때는 3개 기준인지 7개 기준인지 반드시 함께 밝힌다.

5. 재현 파일

용도	경로	상태
코어 둘레 4개 학습	<code>scripts/train_hist_181.py</code>	✓
길이 5개 학습	<code>scripts/train_hist_exact_lengths_v2.py</code>	✓
부가 둘레 3개 학습	—	⚠ 없음 (§ 2.2)
옛/새 길이 정의 비교	<code>scripts/compare_hist_exact_lengths_v2.py</code>	✓
사진 필터	<code>scripts/filter_predictions_to_people.py</code>	✓
VLM 컬럼 정렬	<code>scripts/align_vlm_predictions.py</code>	✓

용도	경로	상태
same-image profile 복구/평가	<code>scripts/build_vlm_image_ground_truth.py</code>	✓
VLM 호출	<code>scripts/run_openrouter.py</code>	✓
행별 예측 (코어 돌레, 172행)	<code>data/hist/predictions/cv_predictions_181.csv</code>	✓
행별 예측 (부가 돌레, 178행)	<code>data/hist/predictions/circumference_cv_predictions.csv</code>	✓

6. Legacy — 참고용, 인용 금지

`metrics.json`과 `manifest.json`은 서빙하지 않는 옛 **11-target** 모델의 산출물이다 (train 3,588 / validation 448 / test 449, holdout 방식). 타깃에 `thigh·calf·arm`이 아예 없어 현재 14개 계약을 만들 수 없으므로 **현재 성능으로 인용하면 안 된다**.

⚠ 이 모델의 행별 예측 파일 4종(`validation_predictions.csv`, `test_predictions.csv`, `vlm_validation_inputs_hist_predictions.csv`, `vlm_test_inputs_hist_predictions.csv`)은 이전 판 문서에 적혀 있었으나 **저장소에 없다**. 학습 스크립트 `scripts/retrain_11targets.py`만 남아 있다.

과거 7개/돌레 기준 실험: `ml/body_measurement/legacy/`,
`ml/body_measurement/data/archive/legacy_7target_vlm/`